

NLP Assignment - Language Modeling & Tokenization

◆ Task 1: Data Selection & Exploratory Data Analysis (EDA)

Đánh giá

Cần thực hiện phân tích đặc điểm ngôn ngữ của từng dataset:

Dataset	Đặc điểm
One Billion Word	Dữ liệu lớn, câu độc lập, không giữ ngữ cảnh dài
WikiText-103	Văn phong Wikipedia, có ngữ cảnh dài, giàu thông tin
Text8	Không có dấu câu, toàn chữ thường
Enwik8	Dữ liệu raw (byte-level), chứa cả ký tự đặc biệt

Cần phân tích các yếu tố:

- Phân bố từ vựng
- Độ dài câu
- Sự hiện diện của dấu câu
- Tính tự nhiên của ngôn ngữ

◆ Task 2: Xây dựng thuật toán Prediction

Đề bài tập trung vào **Language Modeling**

- N-gram models (bigram, trigram)
- RNN / LSTM đơn giản (tự implement, không dùng pre-trained)

Mục tiêu

Xây dựng mô hình có khả năng:

- Dự đoán từ tiếp theo
- Tính toán **Perplexity (PP)**

◆ Task 3: Tokenization (Word, Character, BPE)

Đánh giá

Nội dung cần thực hiện

So sánh 3 phương pháp tokenization:

1. Word-level Tokenization

- Ưu điểm:
 - Dễ hiểu, gần với ngôn ngữ tự nhiên
- Nhược điểm:
 - Vocabulary rất lớn
 - Vấn đề OOV (Out-of-Vocabulary)

2. Character-level Tokenization

- Ưu điểm:
 - Không có OOV
- Nhược điểm:
 - Sequence rất dài
 - Training chậm hơn

3. BPE (Byte Pair Encoding)

- Ưu điểm:
 - Cân bằng giữa word-level và char-level
 - Giảm OOV
- Nhược điểm:
 - Cần training tokenizer

◆ Task 4: Implementation & Evaluation

Đánh giá

1. Vocabulary Size

- Số lượng token trong từ điển

2. Sequence Length

- Độ dài trung bình của chuỗi sau khi tokenize

3. Computational Efficiency

- Thời gian train
- Tốc độ xử lý

4. Perplexity (PP)

- Chỉ số quan trọng nhất
- Đánh giá khả năng dự đoán của mô hình

Tổng kết

Bài toán tập trung vào:

- So sánh các phương pháp **tokenization**
- Áp dụng trên nhiều dataset khác nhau
- Đánh giá bằng **Perplexity** và các chỉ số liên quan

Hướng tiếp cận đúng:

1. EDA kỹ từng dataset
2. Xây dựng language model (N-gram hoặc RNN/LSTM)
3. So sánh Word vs Char vs BPE
4. Đánh giá bằng các metric chuẩn